Homework 2.1 Report

缺失处理

本次实验中采用"全局变量填充"和"平均值填充"两种方式

全局变量填充

在数据集说明的网站www.kaggle.com https://www.kaggle.com/c/dsg-hackathon/data有如下说明

Our intention is to ignore these in calculating your score (MAE). To do achieve that effect, we have (in the solution file) transformed all NA's to "-1,000,000".

因此全局变量我们选用-1,000,000这个值进行填充

平均值填充

在此过程中,我们先对缺失值属性遍历并求出平均值,对于值缺失的项不统计,随后使用平均值进行填充

```
def missingHandler_avg(data, selectedAttr):
   dataList = []
   dataList = copy.deepcopy(data)
   avg = 0.0
   for x in dataList:
       if x[selectedAttr] != 'NA':
           avg += float(x[selectedAttr])
   avg /= len(dataList)
   for x in dataList:
       if x[selectedAttr] == 'NA':
           x[selectedAttr] = "%f" % avg
   return dataList
```

数据规范化

本次实验中采用"最小一最大规范化"和"小数定标规范化"两种方式

最小一最大规范化

最小一最大规范化是采用数据中最小值和最大值作为上下界,加其中的数据按照线性关系进行规范化。在此过程中,我们先求得数据集的最小值和最大值,然后按照规范规则{最小值->0,最大值->1}的方式进行规范化,得到规范化的数据集。为防止缺失值处理过程产生的干扰,我们滤去了取值为"NA"和"-1000000"的数据项

```
def standardize minmax(data, selectedAttr):
   dataList = []
   dataList = copy.deepcopy(data)
   dataMin = 100.0
   dataMax = -100.0
   for x in dataList:
       if x[selectedAttr] == 'NA' or x[selectedAttr] == "-1000000":
           continue
       if float(x[selectedAttr]) < dataMin:</pre>
           dataMin = float(x[selectedAttr])
       if float(x[selectedAttr]) > dataMax:
           dataMax = float(x[selectedAttr])
   for x in dataList:
       x[selectedAttr] = "\%.15f" \% ((float(x[selectedAttr]) - dataMin) / (dataMax - dataMin) * (1)
0) + 0)
   return dataList
```

小数定标规范化

小数定标规范化通常是对取值为小数的属性进行规范化的操作。在此过程中,我们先取得小数中的最大值,并以10的j次幂进行缩小,得到其小于1的最大整数j,并以10的j次幂的幅度对全体数据进行规范化

相关系数分析

采用pearson相关系数r对"Solar.radiation_64"和"target_1_57"进行相关性分析。公式如下

$$r_{A,B} = \frac{\sum_{i=1}^{n} (a_i - \overline{A})(b_i - \overline{B})}{(n-1)\sigma_A \sigma_B} = \frac{\sum_{i=1}^{n} (a_i b_i) - n\overline{AB}}{(n-1)\sigma_A \sigma_B}$$

分别求得x,y两个数组的和、平方和,进而求出公式中其他各项的值并求出最终的结果。求得"Solar.radiation_64"和"target_1_57"的相关系数r=-0.0171368086663

```
def pearson(x,y):
   n = len(x)
   vals = range(n)
   sumx = sum([float(x[i]) for i in vals])
   sumy = sum([float(y[i]) for i in vals])
   sumxSq = sum([x[i] ** 2.0 for i in vals])
   sumySq = sum([y[i] ** 2.0 for i in vals])
   pSum = sum([x[i] * y[i] for i in vals])
   num = pSum - (sumx * sumy / n)
   den = ((sumxSq - pow(sumx, 2) / n) * (sumySq - pow(sumy, 2) / n)) ** 0.5
   return (den == 0 and 0 or num / den)
```

卡方检验分析

使用卡方检验对"weekday"和"Sample.Baro.Pressure_52"属性进行分析。

r行c列数据卡方检验的卡方值=n[(A11/n1n1+A12/n1n2+...+Arc/nrnc)-1]

首先对于数据data,针对两个属性的每个取值先进行分别计数得到sumX和sumY,再根据公式求得Aij/xiyj的和,进而进行计算得到卡方值

最后求得卡方值为5412.53706094